Автоматизация признаков в рекомендательной системе: ядра затухания вместо ручных окон

Abstract

Вопрос. Окно «7 дней» выбрано вручную. Можно ли выбирать масштаб памяти и сами признаки автоматически и заранее понимать по математике, что лучше?

Заранее заданное утверждение (не подтвердилось). Набор `theory_sel` (6 ядер, выбранных жадным отбором по линейному R^2 на лаг-гистограмме, плюс общие признаки «хвоста»: `last`, `age`, конверсии) лучше классики `manual_1_7_30` по auc_user и NDCG@10 в XGBoost, и это не объясняется случайным выбором 6 ядер. Обе части не подтвердились: против классики разница не определена, против подобранных окон `manual_tuned` она отрицательна, а от 6 случайных ядер `theory_sel` не отличим.

Что получилось

1. Самый устойчивый результат: экспоненциальные конверсии (отношения вида «дослушано / прослушано») лучше оконных при тех же полупериодах 7 и 30 дней: +0,0080 по auc_user над классикой, во всех 5 сидах по четырём метрикам. Эффект сохраняется после подбора окон (+0,0048). Подбор окон сам по себе помогает меньше (+0,0048). Полупериоды в экспоненциальных конверсиях выбраны вручную, поэтому это эффект формы ядра, а не автоматического подбора масштаба.
2. При наличии общего хвоста выбор ядер теорией почти ничего не решает: `theory_sel` не отличим от 6 случайных ядер, от 6 ядер со случайным масштабом и от простого top-k.
3. Без хвоста (только 6 ядер) отбор по теории значимо лучше случайного, лучше top-k и лучше случайного масштаба, а предсказанный R^2 умеренно ранжирует наборы (Spearman +0,66 … + 0,73, в основном за счёт разницы между группами наборов). Но полностью автоматический набор ядер без ручного хвоста проигрывает ручному по auc_user на 0,013–0,021.
4. Данные не различают окно в 7 и в 10 дней (одна кривая объяснённой дисперсии плоская; по пяти сидам (этап `scales`) медиана оптимума одной экспоненты равна 19,3 дня для `pair.listen` и 23,9 дня для `pair.good`; для `pair.like` оптимум 161,7 дня лежит почти на краю сетки и малоинформативен. Интервалов для этих медиан нет. Шаг сетки около 1,24 раза, а 7 и 10 дней различаются в 1,43 раза (меньше двух шагов) при плоской кривой, поэтому данные не позволяют сказать, что 7 или 10 дней хуже оптимума; они указывают на оптимум порядка 15–25 дней при широком интервале.).

1 Постановка: что проверялось заранее, а что нет

Проверка заранее заданного утверждения. Утверждение H: `theory_sel` лучше `manual_1_7_30` (и лучше `manual_tuned`) по auc_user и NDCG@10. Правило вердикта зафиксировано до просмотра результатов пяти сидов (заголовок `analyze.py`): разность по каждому сиду, затем t-интервал 95% по сидам (4 степени свободы); «подтверждено», если интервал целиком выше нуля, «опровергнуто», если целиком ниже, иначе «не определено».

Исследовательская часть. После первого просмотра добавлены контроли: `manual_expratios` (убрать разницу в хвосте), случайные ядра, случайный масштаб, top-k, подобранные окна с экспоненциальными конверсиями, объединение окон и экспонент, гистограммы лагов, проверка

двух шкал. Эти результаты описывают данные, но не проверяют заранее заданные гипотезы, и интервалы в них не поправлены на множественность.

2 Связанные работы и математика

Источники. Линейная регрессия, проекции и R^2 стандартны [1]. Центрирование внутри пользователя — within-преобразование панельной эконометрики [2]. Свёртка потока событий с ядром — величина из теоремы Кэмпбелла для точечных процессов [3], ядро Винера $w^* = G^{-1}g$ — дискретный аналог уравнения Винера–Хопфа [4]. Жадный отбор по приросту R^2 — процедура типа ортогонального поиска соответствия (OMP) [5]; гарантии жадного отбора Das и Kempe выражаются через спектральные характеристики ковариации признаков и ослабевают при сильной корреляции [6], на наших данных выполнение условий не проверялось. Бутстрэп по пользователям (кластерный [8], с пуассоновскими весами [9]); общая теория [7]. Время в рекомендательных системах: [12]; датасет [13]; метрики [14, 15]; модель [16].

Признак как фильтр. Признак «число событий за 7 дней» — свёртка потока событий с прямоугольным ядром:

$$f = \sum_k w(T - t_k), \tag{1}$$

где w — ядро памяти, T — момент снапшота. Для экспоненты $w(s) = 2^{-s/h}$ признак обновляется за $O(1)$ без хранения истории: $f_{\text{new}} = f_{\text{old}} \cdot 2^{-\Delta/h} + 1$.

Идеализированная аналитика. Для стационарного пуассоновского входа корреляция выходов двух фильтров равна нормированному скалярному произведению ядер (неравенство Коши–Буняковского). Для $e^{-\lambda s}$ и $e^{-\gamma s}$ получается $\rho^2 = 4\lambda\gamma/(\lambda+\gamma)^2$; для окна ширины w против $e^{-\gamma s}$ — $\rho^2 = 2(1 - e^{-\gamma w})^2/(\gamma w)$. Ошибка полупериода в 1,4 раза (7 против 10 дней) стоит около 3% корреляции признаков, окно в 7 дней при истинном полупериоде 10 даёт $\rho^2 \approx 0{,}61$. Это корреляции признаков при допущениях о стационарности и пуассоновости, а не прирост метрик, и с метриками бустинга они напрямую не сопоставлялись.

Практическая теория. Любой признак «сумма по ядру» линеен по гистограмме лагов X_b (число событий в лаг-бине b): $f = w^\top X$. По достаточным статистикам $G = X^\top X$, $g = X^\top y$ (центрирование внутри пользователя; размер $D \times D$, $D = 6 \cdot 3 \cdot 20 = 360$: семейства × каналы × бины) для набора признаков W получается

$$R^2(W) = \frac{b^\top (WGW^\top)^{-1} b}{y^\top y}, \qquad b = Wg. \tag{2}$$

Статистики накапливаются один раз по train-снапшотам, затем R^2 любого набора считается без обучения бустинга. Отсюда:

- оценка полупериода: arg max по сетке экспонент, интервал — пуассоновский бутстрэп по пользователям;
- ядро Винера $w^* = G^{-1}g$ — потолок R^2 для любых сумм по ядрам *на train*; вне выборки он потолком не является;
- проверка вне выборки: коэффициенты по train, R^2 на val;
- жадный отбор по условному приросту R^2 (формула через дополнение Шура), учитывает избыточность признаков.

Теория линейна, учитывает только ядра (не `last`, `age`, конверсии) и не видит взаимодействий между признаками.

3 Данные и протокол

- **Yambda-50M (flat)** [13]. На каждый из 5 сидов — новая случайная выборка 3000 пользователей (пересечения выборок между сидами не исключались). Обучение: 6 снапшотов с шагом 3 дня; валидация: 1 день; тест: 3 дня подряд. Одна модель на сид; признаки каждого тестового дня считаются по данным до его начала.
- **Кандидаты**: до 150 треков из истории за 30 дней и 50 самых популярных за неделю. **Метка**: дослушано $\geq 50\%$ или лайк в следующие сутки. Признаки строятся строго по событиям $t < T$ (утечка по построению исключена).
- **Метрики**: AUC внутри пользователя (auc_user, основная [14]), NDCG@10 [15], recall@10, общий AUC, logloss. Они считаются *среди кандидатов* и только по пользователям, у которых среди кандидатов есть позитив, поэтому абсолютные значения несопоставимы с бенчмарками Yambda. Метрики сильно определяются повторами пары пользователь–трек; для новых пар (без истории) считаются отдельные метрики.
- **XGBoost на CUDA** [16], одинаковые параметры и ранняя остановка по валидации для всех наборов.
- **Статистика**: разность $A - B$ по каждому сиду (бутстрэп по пользователям внутри сида), затем t-интервал 95% по 5 сидам (4 степени свободы). Это предполагает приблизительную независимость сидов. Сравнения с интервалом, нижний край которого около нуля, считаются неопределёнными. Поправок на множественные сравнения нет. Отсутствие значимости не означает эквивалентности [10].

4 Наборы признаков

5 Результаты

Во всех таблицах разность $A - B$ (больше нуля — A лучше), интервал — t-95% по 5 сидам, в скобках — число сидов, где A лучше. По умолчанию приводятся auc_user и NDCG@10; остальные метрики есть в `analysis.md`.

Набор	auc_user	NDCG@10
`heur_item_pop7` (популярность трека за 7 дней)	0,4491	0,0359
`heur_pair_exp7` (один признак: пара, экспонента 7 дней)	0,7466	0,3389
`manual_1_7_30`	0,8151	0,3635
`manual_expratios`	0,8232	0,3680
`exp_8scales`	0,8262	0,3763

Table 2: Ориентиры: средние по сидам, без интервалов.

Различия между наборами малы в абсолютных значениях. Эффект замены конверсий (+0,0080 по auc_user) составляет около 12% разрыва между одним признаком `heur_pair_exp7` и классикой (0,0685), по NDCG@10 (+0,0046 из 0,0246) около 19%. Популярность трека даёт auc_user ниже 0,5: вероятно, среди кандидатов популярные новые треки реже становятся позитивами, чем треки из истории (не проверялось).

5.1 Заранее заданное утверждение

Вердикт по правилу: против `manual_1_7_30` — не определено по обеим метрикам, против `manual_tuned` — опровергнуто, то есть **утверждение не подтверждено**. Против контролей того же размера

Набор	Описание
`manual_1_7_30`	классика: окна 1/7/30 по 6 семействам × 3 каналам, оконные конверсии, `last`, `age` (70 признаков)
`manual_expratios`	те же 54 ядра, `last`, `age`, но конверсии экспоненциальные (полупериоды 7 и 30 дней, *выбраны вручную*)
`manual_tuned`, `manual_tuned_expratios`	окна подобраны покоординатным спуском по val (без/с экспоненциальными конверсиями)
`rect_8scales`, `exp_8scales`	8 масштабов: окна 0,25–90 дней / экспоненты с полупериодами 0,05–60 дней, 160 признаков
`theory_sel`	6 ядер, выбранных теорией, плюс общий хвост (экспоненциальные конверсии, `last`, `age`), 22 признака
`theory_kernels`	те же 6 ядер без хвоста
`rand6_*`, `krand6_*`	6 случайных ядер из того же пула (без семейства «пользователь») с хвостом / без хвоста
`rscale_t*`, `rscale_k*`	те же семейства, каналы и типы ядер, что у теории, но масштаб случаен (логарифмически равномерно: полупериоды 0,05–150, окна 0,1–110 дней); с хвостом / без
`topk_sel`, `topk_kernels`	6 лучших ядер по одиночному R^2 без жадной коррекции, с хвостом / без
`rect8_exp8_union`	объединение 8 окон и 8 экспонент с общим экспоненциальным хвостом (304 признака)
`lag_hist`, `lag_hist_tail`	непараметрическое ядро: 360 счётчиков по лаг-бинам, без хвоста / с хвостом (376 признаков)

Table 1: Сравниваемые наборы. Семейства ключей: пара пользователь–трек, пользователь–артист (`uart`), пользователь–альбом (`ualb`), трек (`item`), артист (`art`), пользователь. Каналы: прослушивание, дослушано $\geq 50\%$, лайк.

(случайные ядра, случайный масштаб, top-k) разницы нет. Отрицательная разность с `manual_expratios` сравнивает 6 ядер с 54 и о качестве выбора ядер не говорит.

Общий AUC наоборот формально выше у `theory_sel` над классикой (+0,0118 [+0,0060; +0,0175], 5/5), но над `manual_expratios` разницы нет (+0,0014 [−0,0019; +0,0047]). Первоначальный выигрыш `theory_sel` над классикой по общему AUC, по-видимому, объяснялся экспоненциальными конверсиями в хвосте, а не выбором ядер (на одном сиде: 0,8954 против 0,8845).

Вложенные наборы теории. Средние по сидам auc_user (без интервалов): `theory_k1`–`theory_k5`: 0,8156, 0,8158, 0,8165, 0,8168, 0,8168; `theory_sel` (6 ядер): 0,8169; шесть случайных ядер `rand6_0`–`rand6_4`: от 0,8156 до 0,8175. При общем хвосте добавление ядер от 1 до 6 и выбор между теорией и случайным набором меняют метрику менее чем на 0,002. Но это не значит, что ядра вообще не нужны: 54 ядра (`manual_expratios`) дают 0,8232, то есть на 0,006 больше, и `theory_sel` уступает им значимо.

5.2 Конверсии: экспонента против окна

[h]

$A - B$	Δauc_user	ΔNDCG@10
`theory_sel` − `manual_1_7_30`	+0,0017 [−0,0014; +0,0047]	−0,0035 [−0,0086; +0,0015]
`theory_sel` − `manual_tuned`	−0,0032 [−0,0046; −0,0017] (0/5)	−0,0064 [−0,0106; −0,0022] (0/5)
контроли того же размера (6 ядер, общий хвост, 22 признака):		
`theory_sel` − `rand*`	+0,0001 [−0,0024; +0,0025]	+0,0023 [−0,0042; +0,0088]
`theory_sel` − `rscale_t*`	+0,0006 [−0,0008; +0,0020]	+0,0023 [−0,0022; +0,0068]
`theory_sel` − `topk_sel`	+0,0000 [−0,0027; +0,0027]	−0,0006 [−0,0074; +0,0062]
набор большего размера (22 против 70 признаков):		
`theory_sel` − `manual_expratios`	−0,0063 [−0,0088; −0,0039] (0/5)	−0,0081 [−0,0137; −0,0026] (0/5)

Table 3: Теория с общим хвостом.

$A - B$	Δauc_user	ΔNDCG@10
`manual_expratios` − `manual_1_7_30`	+0,0080 [+0,0045; +0,0116] (5/5)	+0,0046 [+0,0006; +0,0085] (5/5)
`manual_tuned` − `manual_1_7_30`	+0,0048 [+0,0026; +0,0071] (5/5)	+0,0028 [−0,0012; +0,0069]
`manual_tuned_expratios` − `manual_tuned`	+0,0048 [+0,0031; +0,0065] (5/5)	+0,0025 [−0,0031; +0,0081]
`manual_expratios` − `manual_tuned`	+0,0032 [+0,0005; +0,0058] (4/5)	+0,0017 [−0,0022; +0,0057]
`manual_tuned_expratios` − `manual_expratios`	+0,0016 [−0,0004; +0,0037]	+0,0008 [−0,0057; +0,0072]

Table 4: Экспоненциальные конверсии, подбор окон и их комбинация.

По общему AUC те же сравнения: +0,0104 [+0,0078; +0,0130] (5/5) для `manual_expratios` над классикой и +0,0021 [+0,0008; +0,0033] (5/5) над `manual_tuned`. Замена оконных конверсий на экспоненциальные улучшает все четыре метрики (auc_user, NDCG@10, recall@10, общий AUC) в каждом из пяти сидов.

Итог.

- Замена даёт больше, чем подбор окон (по auc_user +0,0080 против +0,0048; разность +0,0032, нижний край интервала +0,0005, то есть пограничный результат) и сохраняется после подбора окон.
- Последняя строка: подбор окон поверх экспоненциальных конверсий значимого прироста не показал, но интервал доходит до +0,0037 — это порядка главного эффекта (+0,0032). Поэтому вывод «подбор окон ничего не добавляет» сделать нельзя: данные не исключают эффекта сравнимого размера.
- Полупериоды конверсий (7 и 30 дней) выбраны вручную, как и окна. Результат говорит о форме ядра (или об учёте давности), а не об автоматическом выборе масштаба. Какой именно механизм (гладкость, непрерывные значения, взвешивание давности) отвечает за эффект, не проверялось.

5.3 Много масштабов и форма ядра

Разложение выигрыша над классикой. По auc_user: итого +0,0115, из них конверсии (`manual_expratios` над классикой) +0,0080 (около 70%), масштабы +0,0035 (интервал включает ноль). По NDCG@10 точечные оценки обратные: итого +0,0134, конверсии +0,0046, масштабы +0,0088, при широких интервалах. По общему AUC масштабы дают значимый вклад: +0,0080 [+0,0047; +0,0112] (5/5).

Форма ядра на 8 масштабах по auc_user не определена ни в одном из четырёх сравнений ($|\Delta| \leq 0{,}0012$). Единственный сигнал — NDCG@10 в первой строке плана, и он пограничный

$A - B$	Δauc_user	ΔNDCG@10
`exp_8scales` − `manual_1_7_30`	+0,0115 [+0,0050; +0,0180] (5/5)	+0,0134 [+0,0028; +0,0239] (4/5)
`exp_8scales` − `manual_expratios`	+0,0035 [−0,0021; +0,0091]	+0,0088 [−0,0027; +0,0202]
`exp_8scales` − `rect_8scales_expratios` (форма ядра, конверсии одинаковые)	+0,0009 [−0,0026; +0,0044]	+0,0042 [+0,0000; +0,0083] (5/5)
`exp_8scales_rectratios` − `rect_8scales` (форма ядра, конверсии оконные)	+0,0002 [−0,0037; +0,0041]	−0,0009 [−0,0059; +0,0041]
`rect_8scales_expratios` − `rect_8scales` (конверсии, ядра окна)	+0,0005 [−0,0063; +0,0072]	−0,0041 [−0,0088; +0,0006]
`exp_8scales` − `exp_8scales_rectratios` (конверсии, ядра экспоненты)	+0,0012 [−0,0029; +0,0053]	+0,0010 [−0,0042; +0,0061]

Table 5: 8 масштабов и план «форма ядра × форма конверсий».

(нижний край 0,0000).

$A - B$	Δauc_user	ΔNDCG@10
`rect8_exp8_union` − `rect_8scales_expratios` (экспоненты поверх окон)	+0,0014 [−0,0024; +0,0053]	+0,0062 [+0,0026; +0,0097] (5/5)
`rect8_exp8_union` − `exp_8scales` (окна поверх экспонент)	+0,0005 [−0,0020; +0,0030]	+0,0020 [−0,0040; +0,0080] (4/5)

Table 6: Вложенность. В обоих наборах общий экспоненциальный хвост.

Порядок добавления: окна ∪ экспоненты. Первое направление значимо по NDCG@10, второе нет, но различие между «значимо» и «незначимо» само по себе не значимо [10]. Разность двух приростов равна разности `exp_8scales` − `rect_8scales_expratios` (предыдущая таблица, первая строка плана): NDCG@10 +0,0042 с нижним краем 0,0000, auc_user +0,0009 с интервалом, включающим ноль. Поэтому **надёжной асимметрии нет**. Объединение содержит 304 признака против 160 у каждого из сравниваемых наборов, поэтому прирост нельзя целиком отнести к форме ядра: часть может быть эффектом числа признаков.

5.4 Масштаб памяти: «7 или 10 дней»

В запуске теории на Yambda (**один сид**, 3000 пользователей) для пары пользователь–трек линейный R^2 максимален при полупериоде около 16 дней с бутстрэп-интервалом $[7; 37]$; семидневная экспонента уступает оптимуму около 8%. Кривая плоская, **данные не различают 7 и 10 дней**. Для связки пользователь–артист кривая многопиковая, интервал оптимума одной экспоненты у `uart.good` охватывает почти всю сетку ($[0{,}05; 200]$ дней). По пяти сидам (этап `scales`) медиана оптимума одной экспоненты равна 19,3 дня для `pair.listen` и 23,9 дня для `pair.good`; для `pair.like` оптимум 161,7 дня лежит почти на краю сетки и малоинформативен. Интервалов для этих медиан нет. Шаг сетки около 1,24 раза, а 7 и 10 дней различаются в 1,43 раза (меньше двух шагов) при плоской кривой, поэтому данные не позволяют сказать, что 7 или 10 дней хуже оптимума; они указывают на оптимум порядка 15–25 дней при широком интервале.

5.5 Новые пары (без истории)

Компактные 22-признаковые наборы (`theory_sel`, `rand6_*`) уступают классике по AUC на новых парах на 0,02–0,03, а NDCG@10 на новых парах у `theory_sel` совпадает с классикой (0,4059 против

Набор	AUC на новых парах	NDCG@10 на новых парах
`manual_1_7_30`	0,8431	0,4058
`manual_expratios`	0,8485	0,4134
`exp_8scales`	0,8614	0,4180
`theory_sel`	0,8177	0,4059
`rand6_*` (5 наборов)	0,8143–0,8229	0,3997–0,4037
`manual_kernels` (без хвоста)	0,7780	0,2985
`theory_kernels` (без хвоста)	0,6942	0,3146

Table 7: Метрики на парах без истории; средние по сидам, без интервалов.

0,4058). Широкие наборы (`exp_8scales`) лучше классики по обеим метрикам на новых парах. Для наборов без хвоста картина смешанная: AUC на новых парах у `theory_kernels` ниже, чем у `manual_kernels`, а NDCG@10 выше.

5.6 Теория без хвоста

$A - B$	Δauc_user	ΔNDCG@10	Δ recall@10
`theory\_kernels − krand*`	+0,0585 [+0,0347;+0,0823](5/5)	+0,0766 [+0,0671;+0,0862](5/5)	+0,0836 [+0,0694;+0,0977](5/5)
`rscale\_k* − krand*`	+0,0496 [+0,0247;+0,0745](5/5)	+0,0631 [+0,0495;+0,0767](5/5)	+0,0671 [+0,0502;+0,0840](5/5)
`theory\_kernels − rscale\_k*`	+0,0089 [+0,0066;+0,0112](5/5)	+0,0135 [+0,0080;+0,0190](5/5)	+0,0164 [+0,0104;+0,0225](5/5)
`theory\_kernels − topk\_kernels`	+0,0241 [+0,0109;+0,0372](5/5)	+0,0266 [+0,0216;+0,0316](5/5)	+0,0324 [+0,0266;+0,0381](5/5)
`theory\_kernels − manual\_kernels`	+0,0037 [−0,0023;+0,0097](4/5)	−0,0016 [−0,0068;+0,0035](1/5)	+0,0050 [+0,0032;+0,0067](5/5)

Table 8: Теория без хвоста: 6 ядер против контролей и против 54 ручных ядер.

Разложение. Около 80–85% преимущества над случайными ядрами даёт выбор семейства и канала (разность `rscale_k*` − `krand*` составляет 0,0496 из 0,0585 по auc_user), остальное — выбор масштаба (+0,0089 над случайным масштабом). Случайные ядра `krand*` могут не содержать признаков пары пользователь–трек, и часть разницы объясняется именно этим.

Жадный отбор против top-k: значимо лучше по всем метрикам. Простой top-k без удаления дублей — слабый конкурент: он берёт близкие масштабы одного признака, и вариант с отбором по одному ядру на пару «семейство, канал» не проверялся.

Шесть ядер теории против 54 ручных ядер (оба набора без хвоста): по auc_user и NDCG@10 разница не определена, по recall@10 теория лучше (+0,0050), по общему AUC +0,0202 [+0,0160; +0,0244] (5/5). Эквивалентность этого не доказывает: интервалы широкие. На новых парах картина иная: AUC на новых парах у `theory_kernels` 0,694 против 0,778 у `manual_kernels` (средние по сидам, без интервалов).

Полностью автоматический набор против ручного. Средние по сидам auc_user (без интервалов): `theory_kernels` 0,8023, `manual_1_7_30` 0,8151, `manual_expratios` 0,8232. Набор из 6 автоматически выбранных ядер без `last`, `age` и конверсий уступает ручным наборам на 0,013–0,021 по auc_user; по NDCG@10 средние почти совпадают с классикой (0,3631 против 0,3635) и ниже на 0,005 у `manual_expratios`. Различие в хвосте — главное, что отделяет автоматический набор от ручного.

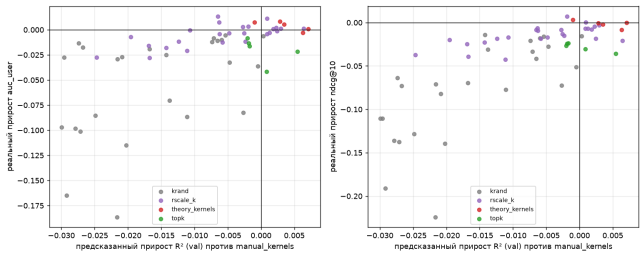


Figure 1: Предсказанный прирост R^2 против реального прироста метрики для наборов без хвоста

5.7 Предсказание до обучения

Ранговая корреляция Spearman между предсказанным приростом R^2 на валидации и реальным приростом метрики (точки — пары «набор, сид», $n = 60$):

Группа наборов	auc_user	NDCG@10
с общим хвостом	+0,02 (среднее по сидам +0,23, диапазон [−0,07; +0,64])	+0,35 (+0,40, [−0,22; +0,78])
без хвоста	+0,66 (+0,72, [+0,55; +0,93])	+0,73 (+0,78, [+0,71; +0,92])
только `krand*` (без хвоста)	+0,50	+0,71

Table 9: Корреляция предсказанного и реального прироста. В скобках — среднее по сидам и диапазон (минимум и максимум по 5 сидам), не доверительный интервал.

Общая корреляция без хвоста отражает в основном разницу между группами (`krand*` слабые, остальные сильные); внутри `krand*` она ниже. Тонкий порядок (жадный отбор против top-k) теория недооценивает: предсказанные разрывы меньше реальных (см. рис.). Возможная причина — нелинейные взаимодействия, которых линейный R^2 не видит; не проверялось. С общим хвостом предсказания не работают.

5.8 Зазор до ядра Винера

Потолок линейных сумм по ядрам (`wiener_all_bins`, R^2 на train): 0,0390. Доля потолка, которую берёт набор:

Набор	Число ядер	R^2	Доля потолка	Зазор
`manual_1_7_30`	54	0,0267	0,686 [0,638; 0,733]	0,0123
`exp_1_best`	18	0,0312	0,802 [0,775; 0,829]	0,0077
`theory_greedy`	6	0,0330	0,848 [0,816; 0,879]	0,0059
`rect_8scales`	144	0,0343	0,880 [0,852; 0,907]	0,0047
`exp_8scales`	144	0,0353	0,906 [0,882; 0,931]	0,0036

Table 10: Зазор до линейного потолка (среднее по 5 сидам, t-интервал).

Результат. Ручные окна 1/7/30 берут около 69% потолка, 8 экспонент — около 91%. Но строки неоднородны: масштаб у `exp_1_best` и `theory_greedy` подобран по тем же train-статистикам, по которым считается R^2, поэтому их доли завышены по построению, а ручные окна фиксированы. Честнее сравнивать 8 окон и 8 экспонент (оба набора с фиксированной сеткой): экспоненты выше на 2,7 п.п. доли потолка [+0,4; +4,9] (в 4 из 5 сидов; интервал построен по долям по сидам). Это утверждение о линейной модели на train; в бустинге та же пара по auc_user не определена.

Потолок вне выборки не гарантирован: на val он может быть ниже, чем у ряда наборов (мало данных на 360 коэффициентов, сильная коллинеарность бинов).

5.9 Непараметрическое ядро

Набор `lag_hist_tail` (360 лаг-счётчиков плюс хвост; бустинг сам учит ядро) не лучше готовых экспонент и окон. По метрикам внутри пользователя разница с `exp_8scales` не определена: auc_user −0,0026 [−0,0070; +0,0017] (1/5), NDCG@10 −0,0084 [−0,0198; +0,0029] (1/5); с `rect_8scales_expratio` — auc_user −0,0017 [−0,0050; +0,0016], NDCG@10 −0,0043 [−0,0133; +0,0047]. По общему AUC хуже `exp_8scales`: −0,0024 [−0,0042; −0,0006] (0/5). Почему так, не проверялось.

5.10 Две временные шкалы

Для каждой пары «семейство, канал» сравнивались лучшая одна экспонента и лучшая смесь двух экспонент (сетка пар) в линейной модели. Показатель d — прирост R^2 на val за счёт смеси минус прирост при второй шкале «наугад» (вложенность делает R^2 смеси на train всегда не ниже одной экспоненты, поэтому смотрим на val и контроль).

Семейство.канал	медиана h одной / пары (дни)	d, прирост R^2		побед	оптимум по терцилям активности (медиана)
`uart.listen`	0,14 / 0,08 и 200	+0,00133 +0,00234]	[+0,00031;	5/5	0,22/200/5,4 (монотонно в 0/5 сидов)
`uart.good`	0,14 / 0,08 и 200	+0,00181 +0,00310]	[+0,00052;	5/5	0,18/0,98/29,5 (монотонно в 2/5)
`ualb.like`	4,35 / 1,86 и 2,8	+0,00026 +0,00043]	[+0,00008;	5/5	200/106/3,5 (0/5)
`item.like`	200 / 162 и 200	+0,00003 +0,00004]	[+0,00002;	5/5	200/200/200 (0/5)

Table 11: Четыре из 15 пар, где d значимо больше нуля. Для остальных 11 (`pair.*`, `uart.like`, `ualb.listen`, `ualb.good`, `item.listen`, `item.good`, `art.*`) интервал включает ноль.

Итог.

- Значимая вторая шкала есть у `uart.listen` и `uart.good`. Лучшая пара — 0,08 и 200 дней, то есть обе шкалы на краях сетки (сетка 0,05–200): это скорее «очень короткий всплеск плюс долгая стабильная симпатия к артисту», чем две выраженные шкалы памяти; сам 200-дневный масштаб при истории 120 дней почти не отличим от константы (за 120 дней истории вес падает примерно на треть).
- Для `item.like` эффект ($3 \cdot 10^{-5}$ по R^2) практически нулевой, оптимумы лежат на краю сетки; для `ualb.like` эффект мал.
- Сдвиг оптимума по терцилям активности не установлен: порядок терцилей непоследователен между сидами (монотонный лишь в 0–2 из 5), а интервалов для оптимумов по стратам в отчёте нет, поэтому альтернативное объяснение («разные пользователи с разной скоростью забывания»; усреднение экспонент даёт степенную кривую [11]) не подтверждено и не опровергнуто.
- Проверка выполнена в линейной модели, в бустинге не проверялась.

6 Выводы

1. **Заранее заданное утверждение не подтвердилось:** `theory_sel` не лучше классики и хуже подобранных окон. Против контролей того же размера (случайные ядра, случайный масштаб, top-k) разницы нет.

2. **Гладкое ядро в конверсиях лучше жёсткого окна** при тех же вручную выбранных полупериодах: +0,0080 по auc_user над классикой, во всех пяти сидах по четырём метрикам; эффект сохраняется при подобранных окнах (+0,0048). Подбор окон помогает меньше; наличие дополнительного эффекта подбора поверх экспоненциальных конверсий данные не исключают.
3. **Много масштабов лучше трёх окон,** но при одинаковом хвосте выигрыш по метрикам внутри пользователя не определён (по auc_user около 70% выигрыша идёт от конверсий, по NDCG@10 оценки обратные). Форма ядра на 8 масштабах не важна; асимметрии «экспоненты поверх окон, но не наоборот» надёжно не показано.
4. **Теория как инструмент отбора:** без общего хвоста значимо лучше случайных ядер, случайного масштаба и top-k (около 80–85% преимущества над случайными даёт выбор семейства и канала); с общим хвостом отбор ядер почти ничего не решает. Предсказанный R^2 умеренно ранжирует наборы без хвоста, тонкий порядок недооценивает и не работает при наличии хвоста.
5. **Полностью автоматический набор ядер без ручного хвоста** проигрывает ручному на 0,013–0,021 по auc_user (по средним по сидам без интервалов); ответ на исходный вопрос задания таков: масштаб ядер можно выбирать автоматически, но главный вклад вносят ручные признаки хвоста.
6. **Масштаб 7 или 10 дней** данными не различается; оценка для пары пользователь–трек — около 16 дней, интервал $[7; 37]$ (один сид).
7. **Ядро Винера:** в линейной модели 8 экспонент берут около 91% потолка, ручные окна около 69%; 8 экспонент выше 8 окон на 2,7 п.п. доли потолка. В бустинге это не воспроизводится по метрикам внутри пользователя.
8. **Непараметрическое ядро** (гистограммы лагов) не лучше экспонент; **две шкалы** статистически значимы для `uart.listen` и `uart.good` (в линейной модели) и выглядят как «короткий всплеск плюс долгая симпатия».

7 Ограничения

- Один датасет (Yambda-50M), пять сидов из него, t-интервал с 4 степенями свободы; выборки пользователей разных сидов могут пересекаться.
- Около 30 пар по трём метрикам, поправок на множественность нет; все сравнения, кроме первого, исследовательские и добавлялись после просмотра результатов. Отсутствие значимости не означает эквивалентности.
- Метрики считаются среди кандидатов (история и популярное), а не на полном каталоге, и сильно определяются повторами; на новых парах результаты для наборов без хвоста иные.
- Параметры XGBoost одинаковы для всех наборов и не подбирались под набор; число ядер ($K = 6$) выбрано произвольно.
- Контроли неидеальны: случайный масштаб включает заведомо слабые значения; `krand*` могут не содержать признаков пары; top-k без удаления дублей слаб.
- Предсказанный R^2 линеен, учитывает только ядра и не видит взаимодействий; ядро Винера — потолок на train, не вне выборки; все R^2-результаты (потолок, две шкалы) относятся к линейной модели.
- Оптимумы масштаба часто лежат на краях сетки (0,05 и 200 дней), история обрезана 120 днями; бутстрэп-интервалы оптимумов очень широки.
- Масштаб в экспоненциальных конверсиях выбран вручную; механизм эффекта конверсий не исследован.
- Идеи с графами и трансформером из условия не реализованы.
- Первая версия анализа содержала ошибку (в группу «с хвостом» попадали наборы без хвоста); исправлена до итоговых цифр. В ранних таблицах `analysis.md` число «побед» для logloss

было инвертировано (меньше — лучше); в итоговой версии `analyze.py` это исправлено.

8 Воспроизведение

```
python download_data.py
python run.py --dataset yambda --size 50m --users 3000 --device cuda \
    --seeds 0,1,2,3,4 --n-test 3 --stages heur,theory,sets,tuned --out results_multi
python run.py ... --stages extra --append --out results_multi
python run.py ... --stages extra2 --append --out results_multi
python run.py ... --stages scales,extra3 --append --out results_multi
python analyze.py --dir results_multi
python wiener_gap.py --dir results_multi
python scales_report.py --dir results_multi
python selected_report.py --dir results_multi
```

Параметры XGBoost (`models.py`): `eta=0.05`, `max_depth=8`, `min_child_weight=5`, `subsample=0.8`, `colsample_bytree=0.6`, `reg_lambda=2.0`, `rounds=3000`, `early_stopping_rounds=60`, `tree_method="hist"`, `device="cuda"`, `max_bin=256`.

Стоимость. Расчёт теории (статистики, отбор, R^2, бутстрэп) выполняется на том же устройстве, что и датасет. По логам запусков: теория около 13 с на сид; обучение XGBoost на 70 признаках около 13 с, на 160 — 26–29 с, на 300–380 — 50–58 с; подбор окон `tuning_seconds` около 372 с на сид.

References

[1] T. Hastie, R. Tibshirani, J. Friedman. *The Elements of Statistical Learning*. Springer, 2nd ed., 2009.

[2] J. D. Angrist, J.-S. Pischke. *Mostly Harmless Econometrics*. Princeton University Press, 2009.

[3] J. F. C. Kingman. *Poisson Processes*. Oxford University Press, 1993.

[4] T. Kailath, A. H. Sayed, B. Hassibi. *Linear Estimation*. Prentice Hall, 2000.

[5] J. A. Tropp. Greed is good: algorithmic results for sparse approximation. *IEEE Trans. Inform. Theory*, 50(10):2231–2242, 2004.

[6] A. Das, D. Kempe. Submodular meets spectral: greedy algorithms for subset selection, sparse approximation and dictionary selection. In *ICML*, 2011.

[7] B. Efron, R. J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall, 1993.

[8] A. C. Cameron, J. B. Gelbach, D. L. Miller. Bootstrap-based improvements for inference with clustered errors. *Review of Economics and Statistics*, 90(3):414–427, 2008.

[9] J. A. Hanley, B. MacGibbon. Creating non-parametric bootstrap samples using Poisson frequencies. *Computer Methods and Programs in Biomedicine*, 83, 2006.

[10] A. Gelman, H. Stern. The difference between "significant" and "not significant" is not itself statistically significant. *The American Statistician*, 60(4):328–331, 2006.

[11] J. M. J. Murre, S. Chessa. Power laws from individual differences in learning and forgetting: mathematical analyses. *Psychonomic Bulletin & Review*, 18, 2011.

[12] Y. Koren. Collaborative filtering with temporal dynamics. In *KDD*, 2009.

[13] Yandex. Yambda-5B — a large-scale multi-modal dataset for ranking and retrieval. arXiv:2505.22238, 2025.

[14] J. A. Hanley, B. J. McNeil. The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology*, 143(1):29–36, 1982.

[15] K. Järvelin, J. Kekäläinen. Cumulated gain-based evaluation of IR techniques. *ACM Trans. Inf. Syst.*, 20(4):422–446, 2002.

[16] T. Chen, C. Guestrin. XGBoost: a scalable tree boosting system. In *KDD*, 2016.